Применение псевдоразметки для распознавания речи

Павел Богомолов, 8.11.2022

План

- Стандартный пайплайн обучения
- Простейшая псевдоразметка (pseudo-labeling)
- Recap: аугментации
- Итеративная псевдоразметка
- slimIPL, экспоненциальное сглаживание учителя
- Объединение wav2vec 2.0 и псевдолейблов
- Софт-лейблы и связь с knowledge distillation

Стандартный пайплайн обучения

- У нас есть размеченные данные L: пары (x, y), где x - звук, y - текст
- Мы обучаем акустическую модель, используя CTC или другой лосс
- Применяем модель: beam-search decoding с LM

Стандартный пайплайн обучения

- Проблема: разметка зачастую дорогая, либо мы вообще не можем ее делать (например, это приватные данные)
- В итоге зачастую количество размеченных данных сильно меньше, чем неразмеченных, но последние мы никак не используем
- Что делать?

Псевдо-разметка

Простейший вариант

- Обучим модель M0 на размеченных данных L
- Возьмем наш неразмеченный датасет U, содержащий звук x_U
- Применим к нему модель: y_U = M0(x_U), используя beam-search и LM
- Обучим на L и (x_U, y_U) новую модель M1
- Применяем модель: beam-search decoding с LM

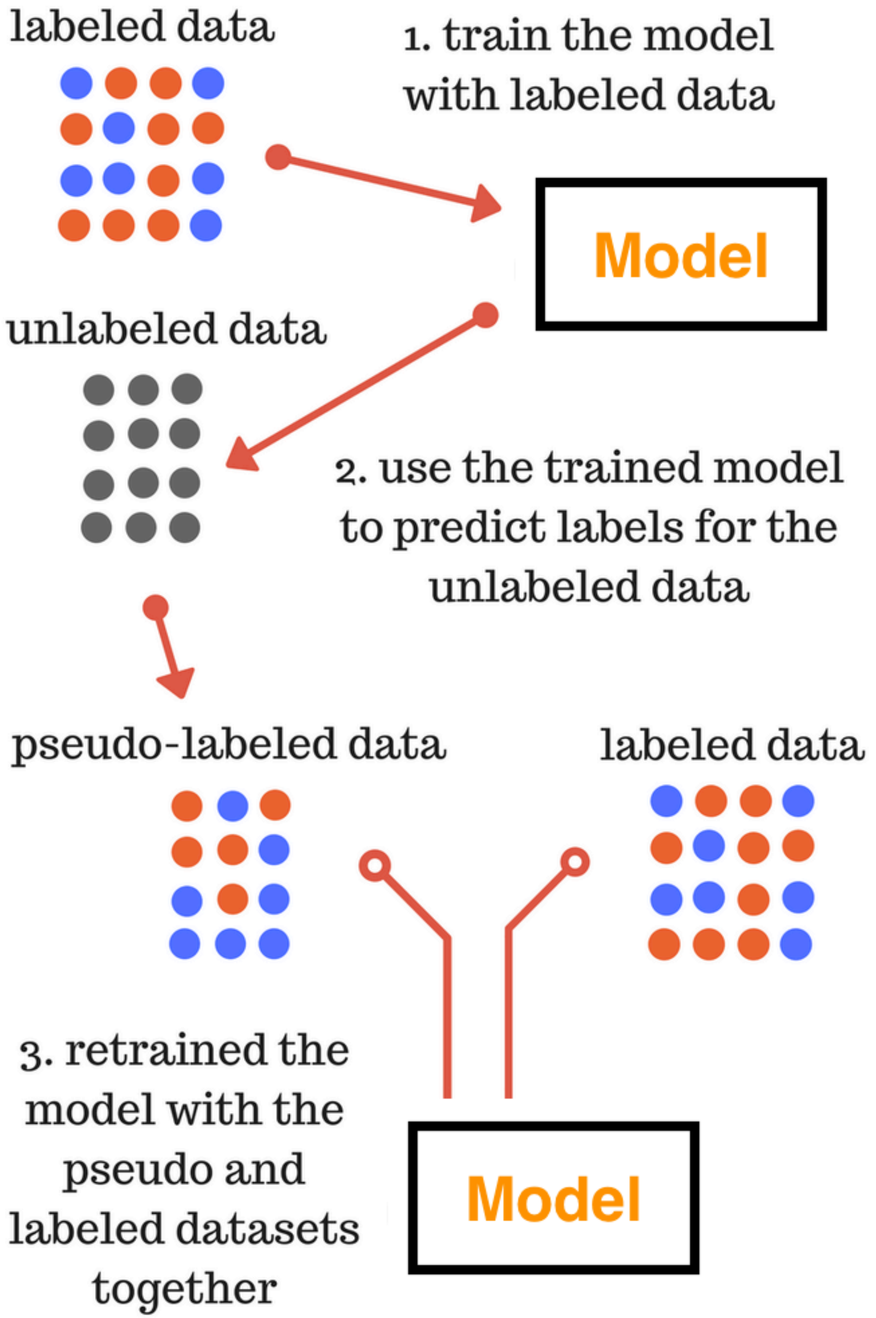

Псевдо-разметка

Почему это работает?

Псевдо-разметка

Почему это работает?

- Интуитивно кажется, что модель не может выучить ничего нового из своих же предсказаний
- На деле:
  - Языковая модель сдвигает предсказание в сторону себя
  - Beam search позволяет получить лучшее предсказание
  - За счет того, что мы берем hard лейблы (не вероятности), это уже получается не совсем то же самое, что простой выход модели
  - Если добавить аугментации при обучении, усложняем M1 задачу еще сильнее

Самые популярные аугментации

(Бонус)

Самые популярные аугментации
(Бонус)

- Ускорение/замедление записи
- Добавление шумов
- SpecAugment: зануляем некоторые фреймы и частоты – самая популярная аугментация в статьях

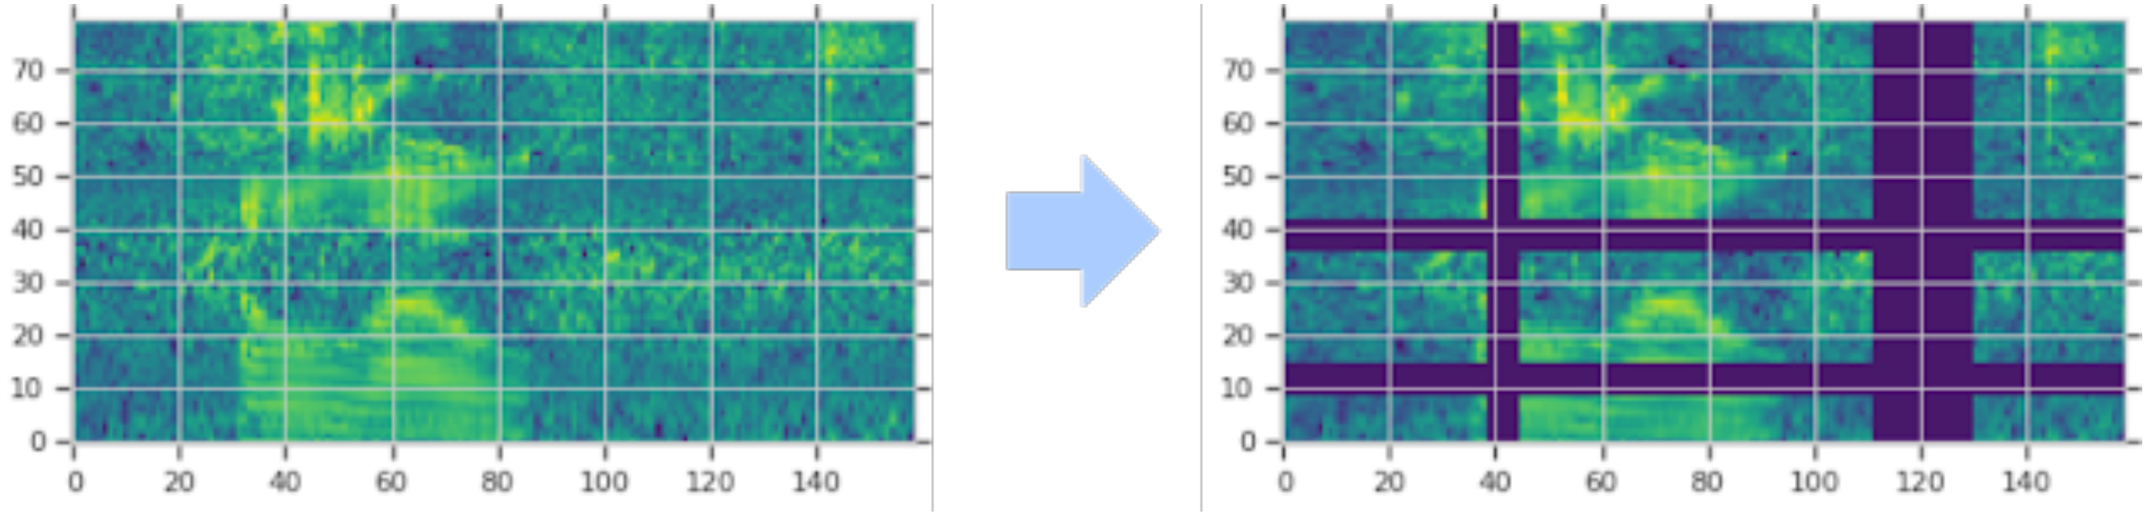

Итеративная псевдоразметка

"Iterative Pseudo-Labeling for Speech Recognition" (Facebook)

- Повторить процесс, обучив модель M2, M3 и т.д.
- Бонус: стартовать с обученных весов, чтобы ускорить процесс

Algorithm 1: Iterative pseudo-labeling

Data: Labeled data $L = \{x_i, y_i\}_{i=1}^{l}$, Unlabeled data $U = \{x'_j\}_{j=1}^{u}$
Result: Acoustic model p_θ
Initialize p_θ by training on only labeled data L;
repeat
1. Draw a subset of unpaired data $\tilde{U} \in U$;
2. Apply p_θ and decoding with LM to the subset $\tilde{U}$ to generate $\hat{U} = \{(x, \hat{y}) | x \in \tilde{U}\}$;
3. Fine tune p_θ on $L \cup \hat{U}$ with data augmentation;

until *convergence or maximum iterations are reached*;

Итеративная псевдо-разметка

"Iterative Pseudo-Labeling for Speech Recognition" (Facebook)

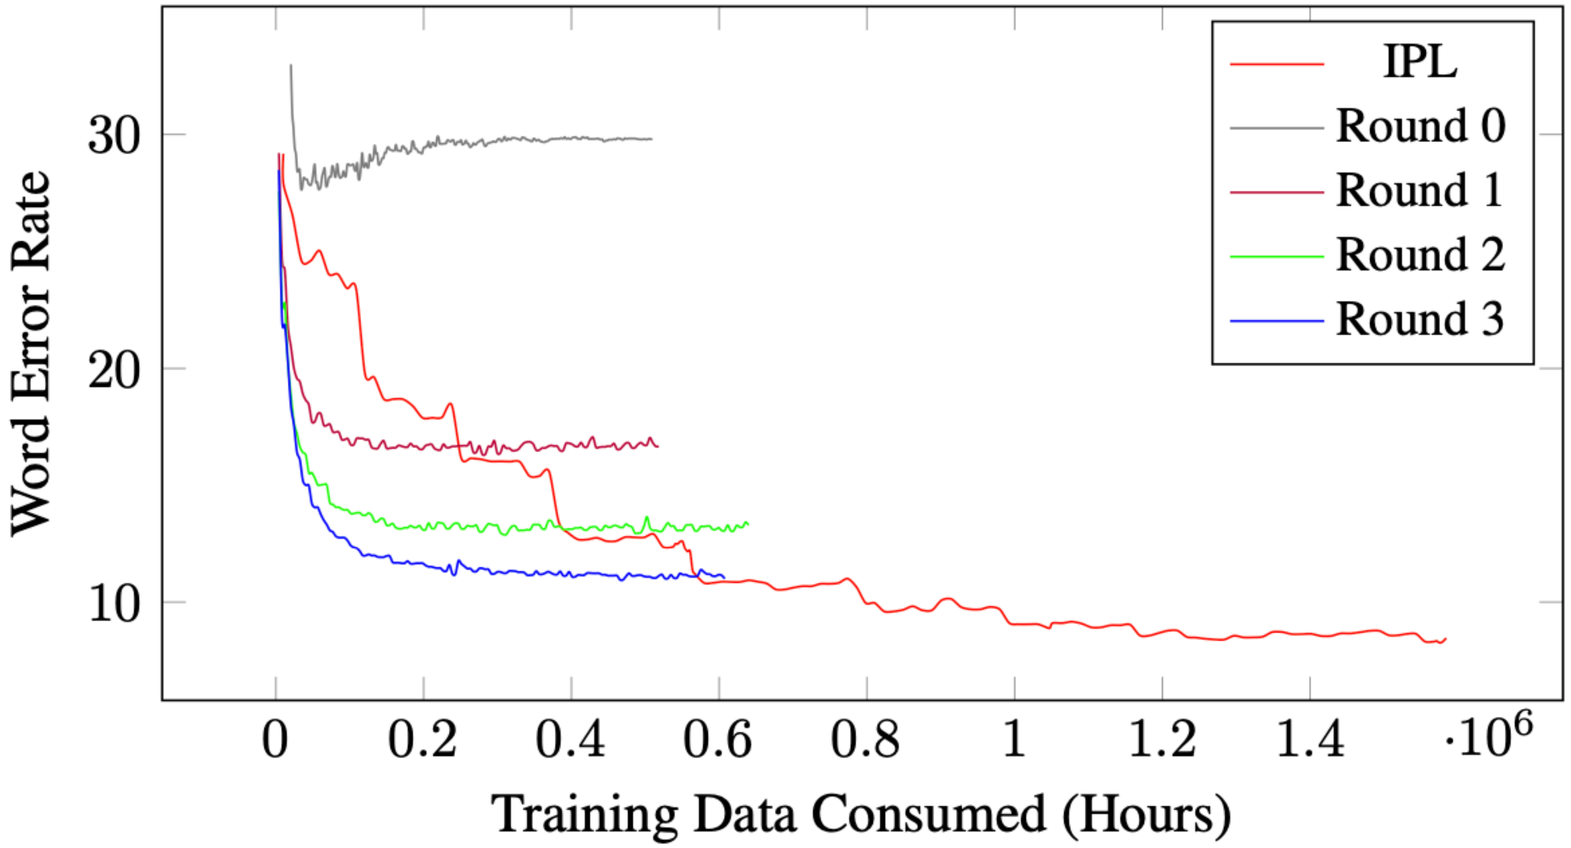

Итеративная псевдо-разметка

"Iterative Pseudo-Labeling for Speech Recognition" (Facebook)

Table 3: WER of greedy path on `dev-other` for IPL and training from scratch for multiple rounds. 4-gram $LS \setminus LV$ LM is used for pseudo-labels generation.

Data		# Rounds of PL				IPL
Labeled	Unlabeled	0	1	2	3	
LS-100	LS-860	27.76	17.1	15.8	15.09	10.69
LS-100	LS + LV	27.76	16.3	12.9	10.95	7.90
LS-960	LV-54K	7.31	5.00	4.69	4.57	4.12

Итеративная псевдоразметка

Проблемы

- Начинаем расходиться со временем
- Псевдолейблы от LAS-моделей плохо работают:
  - модель может выдавать слишком короткие транскрипции *(почему?)*
  - модель может зацикливаться
- Каждый раз перегенерировать предсказания может быть дорого

Итеративная псевдоразметка

Решения

- Начинаем расходиться со временем
  => Храним псевдолейблы от старых версий модели (по сути получаем псевдолейблы от ансамбля всех версий)

- Псевдолейблы от LAS-моделей плохо работают
  => Фильтруем предсказания

- Каждый раз перегенерировать предсказания может быть дорого
  => Убираем LM и beam-search decoding
  Почему оно до сих пор работает? Аугментации!

Про расходимость

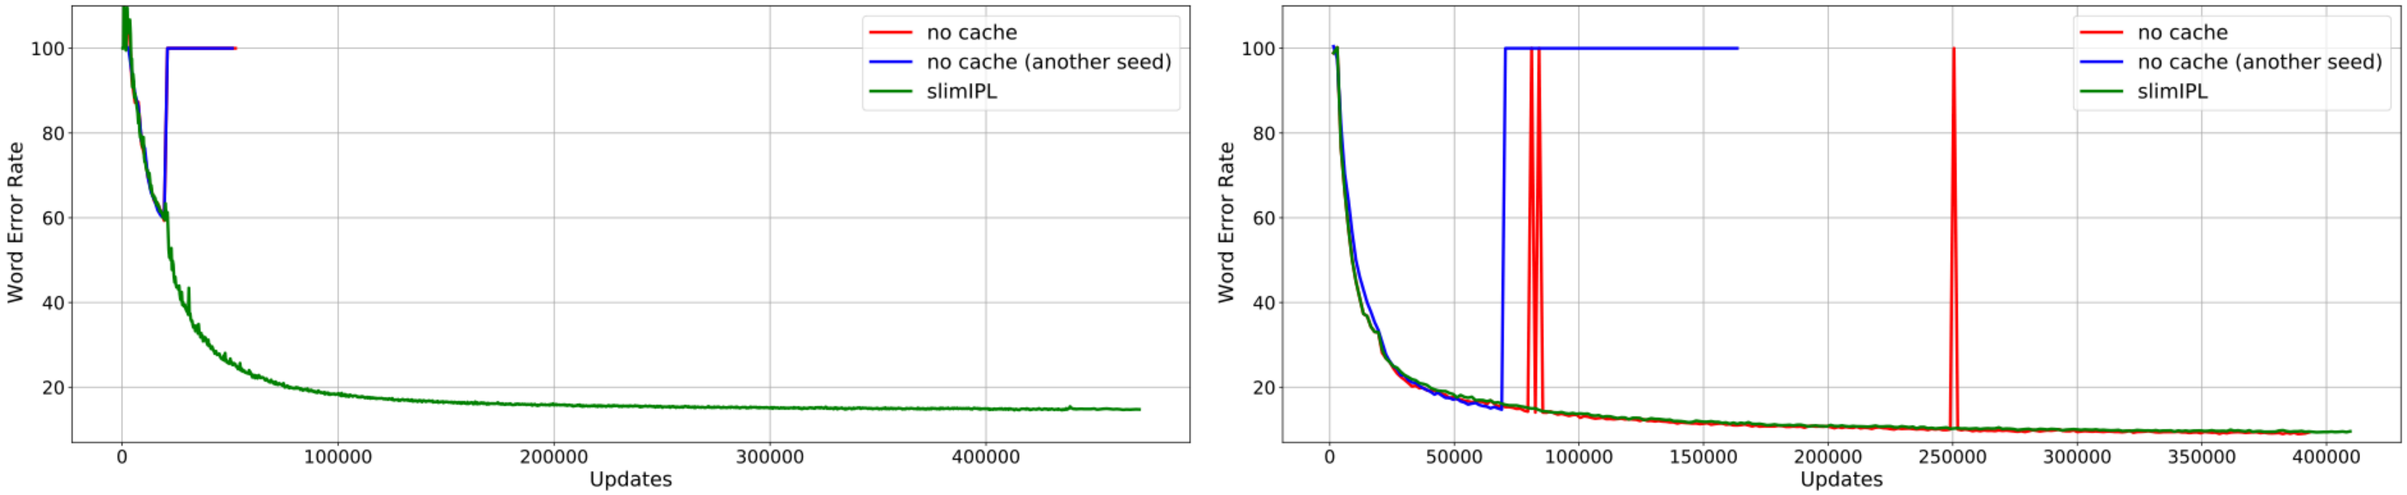

Figure 1: Learning curves on *dev-other* for models trained on LL-10/LS-960 (left) and LS-100/LS-860 (right). slimIPL models refer to baseline models (grey) from Table 3.

Фильтрация

- Можем брать скор языковой модели (Google)
- Можем построить эвристику: смотреть на соотношение длин звука и таргета, отсекать выбросы (Facebook, актуально для LAS-моделей)
- Выкидывать предсказания, где случилось зацикливание (Facebook, LAS)
- Фильтрацию со временем можно ослаблять, это увеличит датасет => можно ослаблять аугментации/регуляризацию
- (А можно наоборот усиливать аугментацию, усложняя задачу для модели)

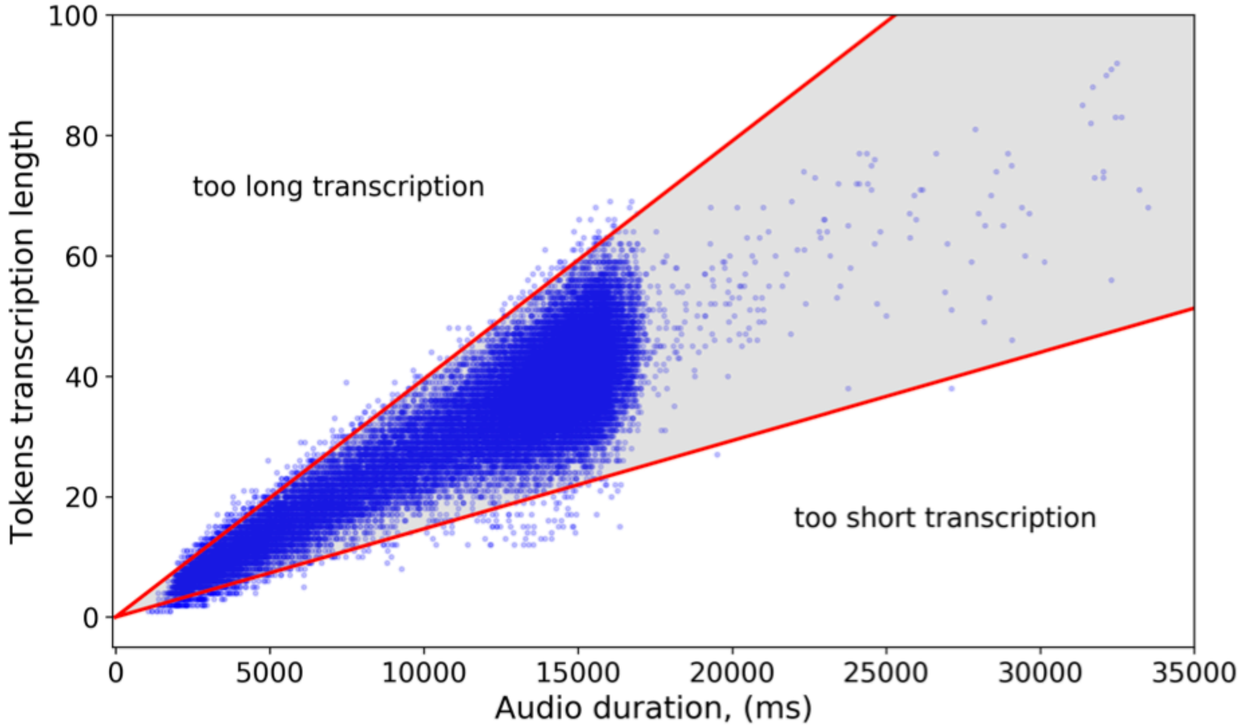

Итеративная псевдоразметка

slimIPL

Algorithm 1: slimIPL

Data: labeled $L = \{\boldsymbol{x}_i, \boldsymbol{y}_i\}$ and unlabeled $U = \{\boldsymbol{x}_j\}$
Result: Acoustic model $\mathcal{M}_\theta$
1. Train $\mathcal{M}_\theta$ on L with augmentation for M updates;
2. **while** *cache is not full at size* C **do**
    - Draw a random batch from $\boldsymbol{x} \in U$;
    - Generate its PL $\hat{\boldsymbol{y}}$ by $\mathcal{M}_\theta$ following Eq.(1);
    - Store $\{\boldsymbol{x}, \hat{\boldsymbol{y}}\}$ into the cache;
    - Train $\mathcal{M}_\theta$ on L with augmentation for 1 update;

end
3. Decrease model's $\mathcal{M}_\theta$ dropout;
repeat
    4. Train $\mathcal{M}_\theta$ on L with augmentation for N_L updates;
    5. **for** N_U *updates* **do**
        - Draw a random batch $B = \{\boldsymbol{x}, \hat{\boldsymbol{y}}\}$ from the cache;
        - **With probability** p, B is removed from cache and a new pair of random batch $\boldsymbol{x}' \in U$ and its PL $\hat{\boldsymbol{y}}'$ generated by $\mathcal{M}_\theta$ is added in;
        - Apply augmentation to batch B and make an optimization step to update $\mathcal{M}_\theta$.

    end
until *convergence or maximum iterations are reached*;

Итеративная псевдоразметка

slimIPL

Table 2: Comparison with other semi- and unsupervised methods: LL-10/LS-960 (top) and LS-100/LS-860 (bottom).

Method	Stride	Tokens	Criterion	LM	Dev WER		Test WER		Compute Resources		
					clean	other	clean	other	Train Time (Days)	# G/TPUs	G/TPU-days
Libri-Light [2]	20 ms	letters	CTC	word 4-gram	30.5	55.8	30.1	57.2	-	-	-
IPL [5]	80ms	5k wp	CTC	-	23.8	25.7	24.6	26.5	3	64 GPUs	192
				+ rescoring	23.5	25.5	24.4	26.0			
wav2vec 2.0 [28]	20ms	letters	CTC	-	8.1	12.0	8.0	12.1	2.3	128 GPUs	294.4
				word 4-gram	3.4	6.9	3.8	7.3			
				word Transf.	2.9	5.7	3.2	6.1			
slimIPL	30ms	letters	CTC	-	11.4	14	11.4	14.7	4.7	16 GPUs	75.2
				word 4-gram	6.6	9.6	6.8	10.5			
				+ rescoring	5.3	7.9	5.5	9.0			
IPL [5]	80ms	5k wp	CTC	-	5.5	9.3	6.0	10.3	3	64 GPUs	192
				+ rescoring	5.0	8.0	5.6	9.0			
Improved T/S [9]	-	16k wp	S2S	-	4.3	9.7	4.5	9.5	10×5	32 TPUs	1600
				LSTM	3.9	8.8	4.2	8.6			
wav2vec 2.0 [28]	20ms	letters	CTC	-	4.6	9.3	4.7	9.0	2.3	128 GPUs	294.4
				word 4-gram	2.3	5.7	2.8	6.0			
				word Transf.	2.1	4.8	2.3	5.0			
slimIPL	30ms	letters	CTC	-	3.7	7.3	3.8	7.5	5.2	16 GPUs	83.2
				word 4-gram	2.8	5.6	3.1	6.1			
				+ rescoring	2.2	4.6	2.7	5.2			

EMA

- Вместо хранения псевдолейблов от старых версий модели можно усреднять веса с разных версий
- Перебирая параметры alpha и Delta, мы будем больше склоняться к более новым или более старым версиям
- Ищем баланс между расхождением и субоптимальным качеством

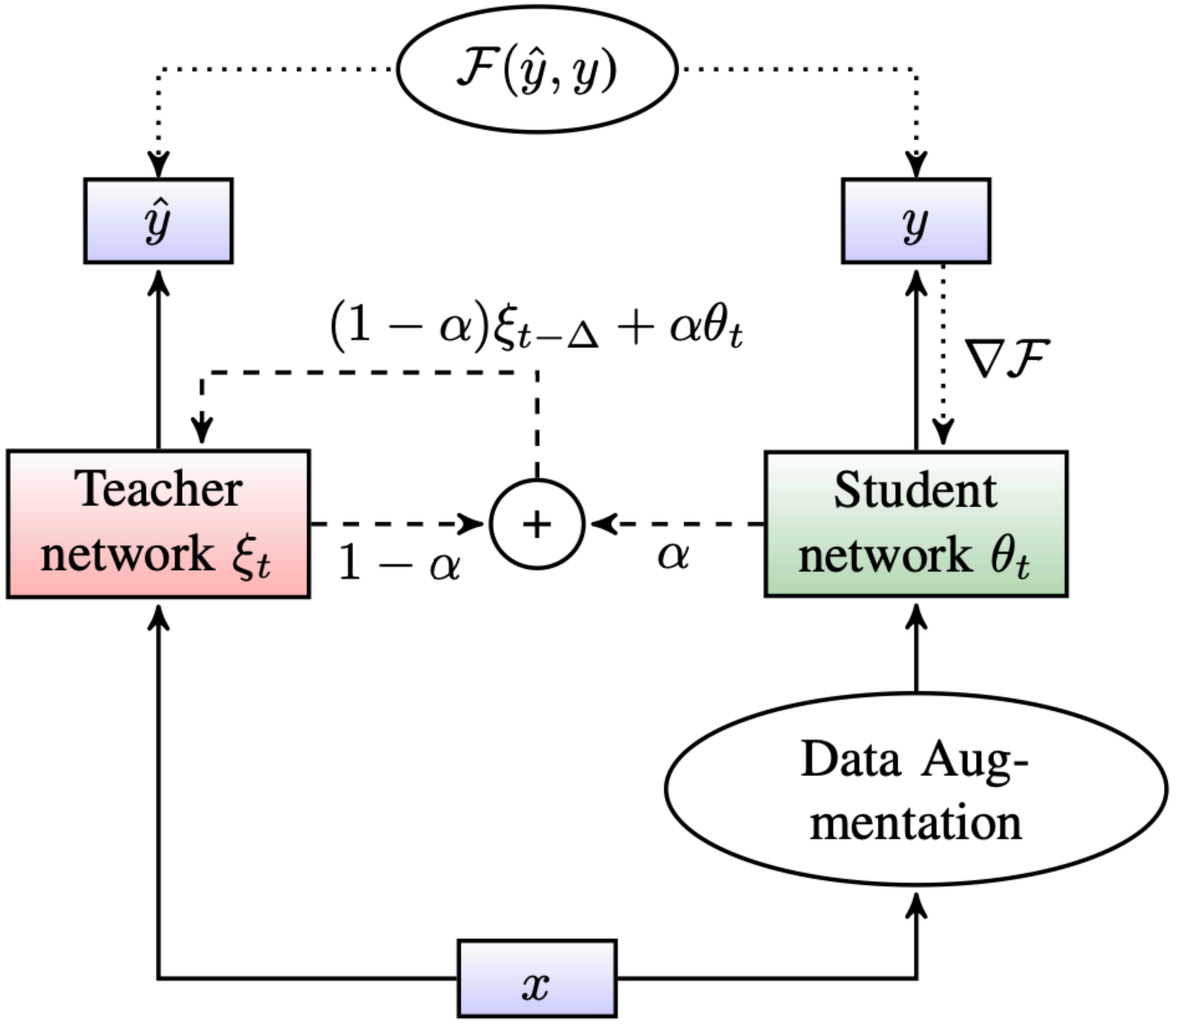

Fig. 1. Block diagram of the Kaizen framework.

wav2vec 2.0 + псевдолейблы

- обучаем wav2vec, файн-тюним на размеченном датасете, генерируем псевдолейблы
- особенно полезно, если у нас совсем мало разметки
- fun fact: LAS дополнительно выигрывает от псевдолейблов, т.к. декодер меньше переобучается

Table 3: WER on Librispeech with and without a language model (LM) for 10 min, and 960h of labeled data and LibriVox as unlabeled data.

Model	dev		test	
	clean	other	clean	other
10 min labeled				
wav2vec 2.0 [24]	5.0	8.4	5.2	8.6
- LM	38.3	41.0	40.2	38.7
wav2vec 2.0 + ST (s2s scratch)	2.6	4.7	3.1	5.4
- LM	3.3	5.9	3.7	6.5
wav2vec 2.0 + ST (ctc ft)	2.8	4.6	3.0	5.2
- LM	4.2	6.9	4.3	7.2
960h labeled				
wav2vec 2.0 [24]	1.6	3.0	1.8	3.3
- LM	2.1	4.5	2.2	4.5
wav2vec 2.0 + ST (s2s scratch)	1.1	2.7	1.5	3.1
- LM	1.3	3.1	1.7	3.5
wav2vec 2.0 + ST (ctc ft)	1.6	2.9	1.8	3.3
- LM	1.7	3.6	1.9	3.9

Soft labels

- Мы можем подавать софт-лейблы (иначе говоря логиты) вместо хард-лейблов => получаем по сути классическую дистилляцию
- Соответственно, нужен другой лосс (KL divergence)
- Плохо работает в комбинации с CTC/RNN-T *(почему?) — исключение: self-training* https://arxiv.org/abs/2210.05793
- Если стартовать с тех же весов, то лосс может стать равен нулю :) Поэтому аугментации особенно актуальны

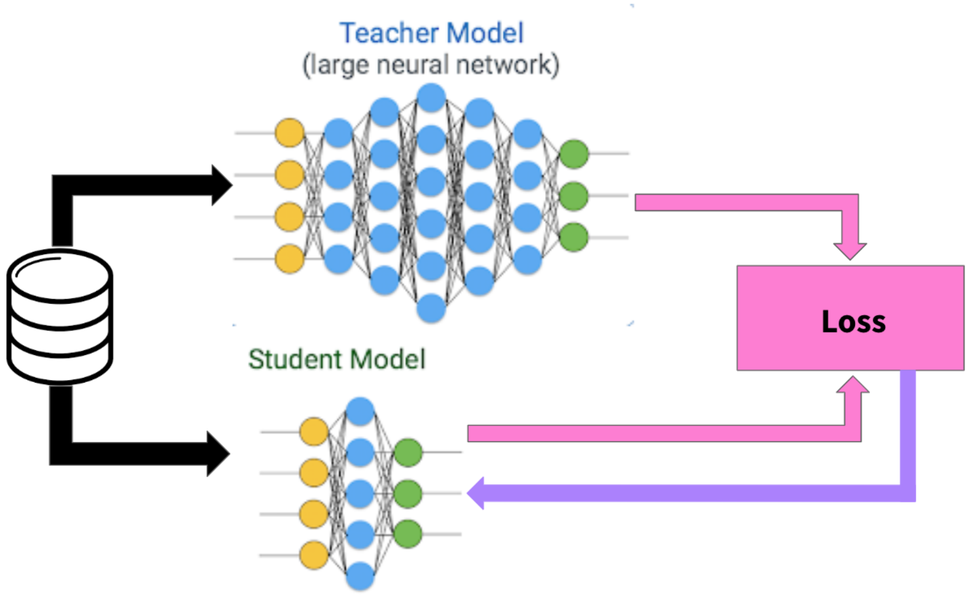

Дистилляция

Используем ансамбль моделей в качестве учителя

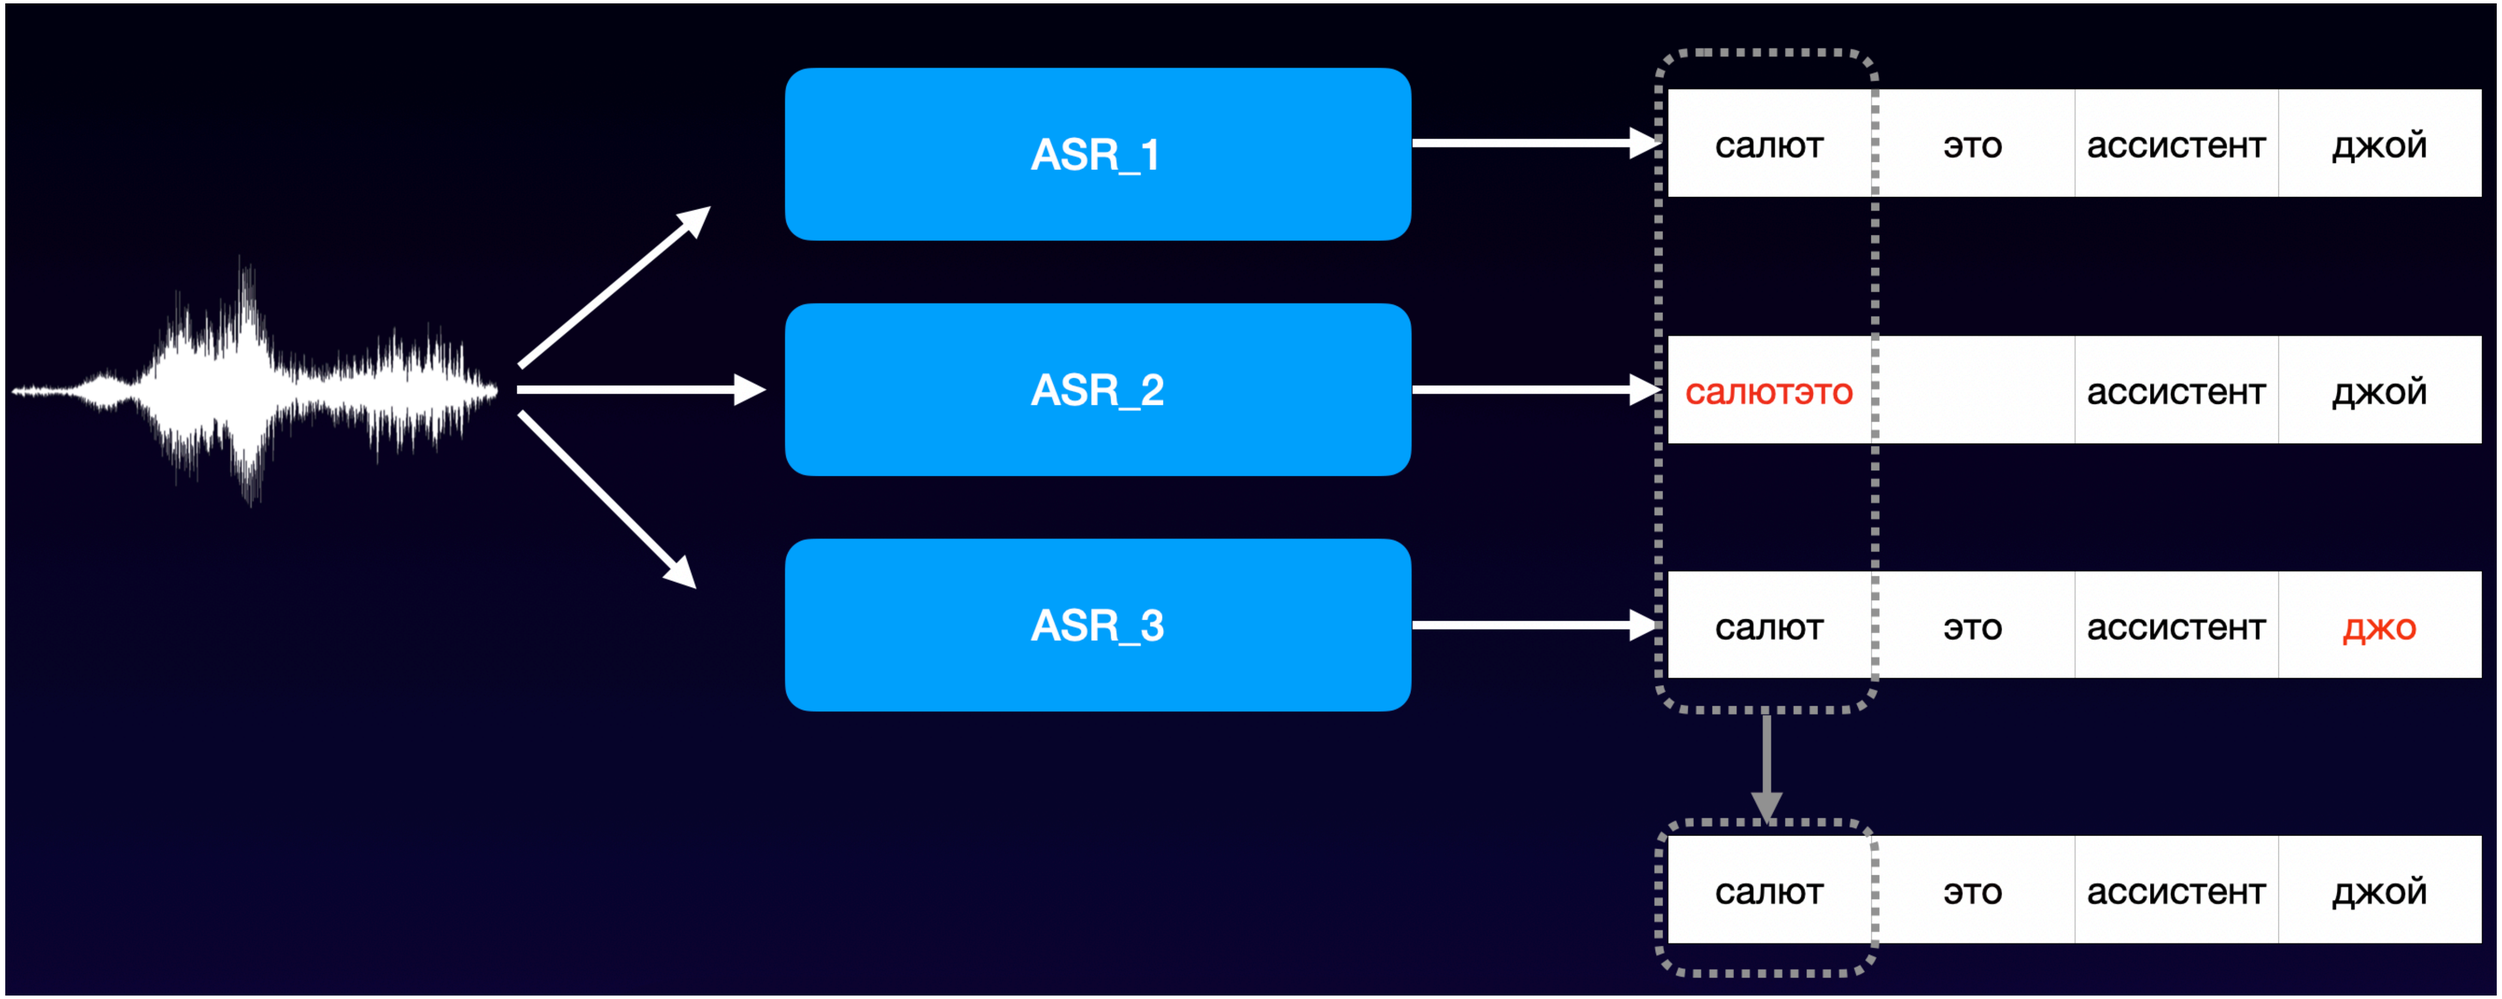

Recap

- Псевдолейблы помогают использовать неразмеченные данные и улучшать качество
- Псевдолейблы дают модели новую информацию за счет:
  - beam search decoding'a
  - языковой модели
  - аугментаций
  - более сильных моделей-учителей (включая ансамбли)
- Делая новые итерации псевдолейблов, мы улучшаем качество еще больше
- Unsupervised pre-training дает дополнительный профит
- Можно использовать софт-лейблы, получая от них дополнительную информацию (плохо работает для CTC)

Спасибо! Вопросы? :)